

Формулировка и решение задачи оптимизации, сочетающей классификацию и регрессию, для оценки энергии связывания белка и маленьких молекул

Анастасия Грачева, Мария Кадукова, Сергей Грудинин, В.В. Стрижов
gracheva.as@phystech.edu

¹ФИВТ МФТИ

При разработке лекарства возникает задача поиска маленьких молекул - лигандов, наиболее сильно взаимодействующих с исследуемым белком, а значит являющихся основными кандидатами в лекарства. Один из способов определить действительное положение такого лиганда заключается в том, чтобы генерировать несколько возможных положений и классифицировать их как нативные и не нативные. Но качество предсказания может быть повышено, если использовать экспериментальные данные о свободной энергии связывания молекул и решать одновременно задачи регрессии и классификации. В статье будут рассмотрены эксперименты с алгоритмом, использующим эту идею.

1 Введение

Предсказание наиболее выгодной ориентации и положения молекул по отношению друг к другу для образования устойчивого комплекса из белка и лиганда, или молекулярный докинг - задача, важная для ускорения процесса разработки новых лекарств. Есть два метода её решения: pose prediction - среди нескольких сгенерированных положений лиганда в белке определить наиболее близкое к реальному и scoring - предсказать аффинность (свободную энергию связывания) для комплексов различных белков с лигандами. При этом положение с наименьшей энергией связывания будет соответствовать нативной конформации. Первая задача решена в работе [1] с помощью оптимизации скоринговой функции, учитывающей всевозможные комбинации различных пар атомов и расстояния между ними. Раскладывая эту функцию по базису, авторы представляют её как вектор структурных коэффициентов и сводят задачу к модифицированной SVM-классификации.

Наше предположение заключается в том, что с использованием экспериментальных данных об аффинностях можно улучшить качество классификации. В эксперименте, описанном в данной статье, мы проверим эту гипотезу, а также постараемся решать оптимизационную задачу максимально эффективно вычислительно, чтобы использовать как можно больше доступных экспериментальных данных.

2 Постановка задачи

Пусть $\{C_{ij}\}_{i=1}^P$ - комплексы белков и лигандов. При $j = 0$ они находятся в нативных позах, при $j = 1 \dots D$ - в ненативных. Задача заключается в том, чтобы найти скоринговую функцию E , который удовлетворяет неравенствам:

$$\begin{aligned} E(C_{i0}) &< E(C_{ij}) \\ \forall i &\in 1, \dots, P, \\ \forall j &\in 1, \dots, D. \end{aligned} \tag{1}$$

В модели взаимодействия, описанной в [1], эта функция задаётся скоринговым вектором \mathbf{w} . Поэтому неравенство выше может быть преобразовано в систему неравенств:

$$\begin{aligned}
\langle \mathbf{x}_{i0}, \mathbf{w} \rangle &< \langle \mathbf{x}_{ij}, \mathbf{w} \rangle, \\
\langle \mathbf{x}_{ij} - \mathbf{x}_{i0}, \mathbf{w} \rangle &> 0, \\
\forall i &= 1, \dots, P, \\
\forall j &= 1, \dots, D.
\end{aligned} \tag{2}$$

где x_{ij} - структурные вектора.

Чтобы гарантировать единственность решения, а также решать задачу в случае линейной неразделимости выборки, приведём её к виду задачи квадратичной оптимизации с мягким зазором:

$$\begin{aligned}
\underset{\mathbf{w}, b_i, \xi_{ij}}{\text{minimize:}} \quad & \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{ij} \xi_{ij} \\
\text{subject to:} \quad & y_{ij}[\langle \mathbf{w}, \mathbf{x}_{ij} \rangle - b_i] - 1 + \xi_{ij} \geq 0, \\
& \xi_{ij} \geq 0, \\
& i \in \{1, \dots, P\}, \\
& j \in \{0, \dots, D\},
\end{aligned} \tag{3}$$

где \mathbf{w} , b_i и переменные невязки ξ_{ij} – оптимизируемые параметры модели, $y_{i0} = 1$ для нативной позы и $y_{ij} = -1$, $j \in \{1, \dots, D\}$, для ненативной, а C – некоторый коэффициент регуляризации.

Таким образом, решив оптимизационную задачу, решаем и задачу классификации.

Кроме того, есть другая постановка этой задачи - задача регрессии, т.е. предсказания значения свободной энергии связывания белка с лигандом:

$$\begin{aligned}
\underset{\mathbf{w}}{\text{minimize:}} \quad & \sum_i [\langle \mathbf{w}, \mathbf{x}_{i0} \rangle - s_i]^2 + \alpha \|\mathbf{w}\|^2, \\
& i \in \{1, \dots, P\},
\end{aligned} \tag{4}$$

где s_i – экспериментально полученное значение энергии связывания i -го нативного соединения, α – коэффициент регуляризации для ridge-регрессии.

Объединение этих методов заключается в сложении функций потерь классификации и регрессии:

$$\begin{aligned}
\underset{\mathbf{w}, b_i, \xi_{ij}}{\text{minimize:}} \quad & \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{ij} \xi_{ij} + C_r \sum_i f(\mathbf{x}_{i0}, \mathbf{w}, s_i) \\
\text{subject to:} \quad & y_{ij}[\langle \mathbf{w}, \mathbf{x}_{ij} \rangle - b_i] - 1 + \xi_{ij} \geq 0, \\
& \xi_{ij} \geq 0, \\
& i \in \{1, \dots, P\}, \\
& j \in \{0, \dots, D\},
\end{aligned} \tag{5}$$

где $f(\mathbf{x}_{i0}, \mathbf{w}, s_i)$ – MSE, C_r – коэффициент регуляризации для функции потерь регрессии.

3 Теоретическая часть

С помощью замены переменных сведем два квадратичных слагаемых в целевой функции из задачи (5) к одному.

Функция потерь регрессии MSE для одного комплекса выражается формулой:

$$f(\mathbf{x}_{i0}, \mathbf{w}, s_i) = (\langle \mathbf{x}_{i0}, \mathbf{w} \rangle - s_i)^2. \tag{6}$$

Тогда для выборки $\mathbf{X} = (\mathbf{x}_{10}, \dots, \mathbf{x}_{P0})^T$, состоящей из нативных конфигураций, и целевого вектора $\mathbf{s} = (s_1, \dots, s_P)^T$ квадратичные слагаемые целевой функции из задачи (5) принимают вид:

$$\begin{aligned} \frac{1}{2}\|\mathbf{w}\|^2 + C_r \sum_i f(\mathbf{x}_{i0}, \mathbf{w}, s_i) &= \frac{1}{2}\mathbf{w}^T \mathbf{w} + C_r \|\mathbf{X}\mathbf{w} - \mathbf{s}\|^2 = \\ &= \frac{1}{2}\mathbf{w}^T \mathbf{w} + C_r \mathbf{w}^T \mathbf{X}^T \mathbf{X} \mathbf{w} - 2C_r \mathbf{w}^T \mathbf{X}^T \mathbf{s} + C_r \mathbf{s}^T \mathbf{s} = \\ &= \mathbf{w}^T \left(\frac{1}{2}\mathbf{I} + C_r \mathbf{X}^T \mathbf{X} \right) \mathbf{w} - 2C_r \mathbf{w}^T \mathbf{X}^T \mathbf{s} + C_r \mathbf{s}^T \mathbf{s} = \\ &= \left\| \left[\frac{1}{2}\mathbf{I} + C_r \mathbf{X}^T \mathbf{X} \right]^{\frac{1}{2}} \mathbf{w} \right\|^2 - 2C_r \left(\mathbf{w}^T \left[\frac{1}{2}\mathbf{I} + C_r \mathbf{X}^T \mathbf{X} \right]^{\frac{1}{2}} \right) \left(\left[\frac{1}{2}\mathbf{I} + C_r \mathbf{X}^T \mathbf{X} \right]^{-\frac{1}{2}} \mathbf{X}^T \mathbf{s} \right) + C_r \mathbf{s}^T \mathbf{s} = \\ &= \left(\left[\frac{1}{2}\mathbf{I} + C_r \mathbf{X}^T \mathbf{X} \right]^{\frac{1}{2}} \mathbf{w} - C_r \left[\frac{1}{2}\mathbf{I} + C_r \mathbf{X}^T \mathbf{X} \right]^{-\frac{1}{2}} \mathbf{X}^T \mathbf{s} \right)^2 + C_r \mathbf{s}^T \mathbf{s} - C_r^2 \left\| \left[\frac{1}{2}\mathbf{I} + C_r \mathbf{X}^T \mathbf{X} \right]^{-\frac{1}{2}} \mathbf{X}^T \mathbf{s} \right\|^2. \end{aligned}$$

Введем замену переменных:

$$\begin{aligned} \mathbf{w}' &= \mathbf{A}\mathbf{w} - \mathbf{B}, \text{ где} \\ \mathbf{A} &= \left[\frac{1}{2}\mathbf{I} + C_r \mathbf{X}^T \mathbf{X} \right]^{\frac{1}{2}}, \\ \mathbf{B} &= C_r \left[\frac{1}{2}\mathbf{I} + C_r \mathbf{X}^T \mathbf{X} \right]^{-\frac{1}{2}} \mathbf{X}^T \mathbf{s}. \end{aligned} \tag{7}$$

Тогда, учитывая, что

$$C_r \mathbf{s}^T \mathbf{s} - C_r^2 \left\| \left[\frac{1}{2}\mathbf{I} + C_r \mathbf{X}^T \mathbf{X} \right]^{-\frac{1}{2}} \mathbf{X}^T \mathbf{s} \right\|^2 = \text{const},$$

задача оптимизации принимает вид:

$$\begin{aligned} \underset{\mathbf{w}', b_i, \xi_{ij}}{\text{minimize:}} \quad & \frac{1}{2}\|\mathbf{w}'\|^2 + C \sum_{ij} \xi_{ij} \\ \text{subject to:} \quad & y_{ij}[(\mathbf{A}^{-1}(\mathbf{w}' + \mathbf{B}))^T \mathbf{x}_{ij} - b_i] - 1 + \xi_{ij} \geq 0, \\ & \xi_{ij} \geq 0, \\ & i \in \{1, \dots, P\}, \\ & j \in \{0, \dots, D\}. \end{aligned} \tag{8}$$

Введем обозначение:

$$\hat{\mathbf{X}} = (\mathbf{A}^{-1})^T \mathbf{X}. \tag{9}$$

Найдём двойственную задачу:

$$\begin{aligned}\mathcal{L}(\mathbf{w}', \mathbf{b}, \xi, \lambda, r) &= \frac{1}{2} \|\mathbf{w}'\|^2 + C \sum_{ij} \xi_{ij} - \sum_{ij} \lambda_{ij} (y_{ij} [\langle \mathbf{A}^{-1}(\mathbf{w}' + \mathbf{B}), \mathbf{x}_{ij} \rangle - b_i] - 1 + \xi_{ij}) - \sum_{ij} r_{ij} \xi_{ij} \\ \frac{\partial \mathcal{L}}{\partial \mathbf{w}'} &= \mathbf{w}' - \sum_{ij} \lambda_{ij} y_{ij} \langle \mathbf{A}^{-1}(\mathbf{w}' + \mathbf{B}), \mathbf{x}_{ij} \rangle'_{\mathbf{w}'} = 0 \rightarrow \mathbf{w}' = \sum_{ij} \lambda_{ij} y_{ij} \mathbf{A}^{-1} \mathbf{x}_{ij} \\ \forall i, \frac{\partial \mathcal{L}}{\partial b_i} &= \sum_j \lambda_{ij} y_{ij} = 0 \\ \forall (i, j), \frac{\partial \mathcal{L}}{\partial \xi_{ij}} &= C - \lambda_{ij} - r_{ij} = 0 \rightarrow \lambda_{ij} + r_{ij} = C\end{aligned}\tag{10}$$

$$\begin{aligned}\mathcal{L}(\lambda, r) &= \frac{1}{2} \langle \sum_{ij} \lambda_{ij} y_{ij} \mathbf{A}^{-1} \mathbf{x}_{ij}, \sum_{ij} \lambda_{ij} y_{ij} \mathbf{A}^{-1} \mathbf{x}_{ij} \rangle + C \sum_{ij} \xi_{ij} - \sum_{ij} \lambda_{ij} y_{ij} \langle \mathbf{A}^{-1} \sum_{ij} \lambda_{ij} y_{ij} \mathbf{A}^{-1} \mathbf{x}_{ij}, \mathbf{x}_{ij} \rangle - \\ &- \sum_{ij} \lambda_{ij} y_{ij} \langle \mathbf{A}^{-1} \mathbf{B}, \mathbf{x}_{ij} \rangle + \sum_{ij} \lambda_{ij} y_{ij} b_i + \sum_{ij} \lambda_{ij} - \sum_{ij} \lambda_{ij} \xi_{ij} - \sum_{ij} r_{ij} \xi_{ij} = \\ &= \frac{1}{2} \sum_{ij} \sum_{pq} \lambda_{ij} \lambda_{pq} y_{ij} y_{pq} \langle \mathbf{A}^{-1} \mathbf{x}_{ij}, \mathbf{A}^{-1} \mathbf{x}_{pq} \rangle + \sum_{ij} \xi_{ij} (C - \lambda_{ij} - r_{ij}) - \sum_{ij} \sum_{pq} \lambda_{ij} \lambda_{pq} y_{ij} y_{pq} \langle \mathbf{A}^{-2} \mathbf{x}_{ij}, \mathbf{x}_{pq} \rangle - \\ &- \sum_{ij} \lambda_{ij} y_{ij} \langle \mathbf{A}^{-1} \mathbf{B}, \mathbf{x}_{ij} \rangle + \sum_i b_i \sum_j \lambda_{ij} y_{ij} + \sum_{ij} \lambda_{ij}\end{aligned}\tag{11}$$

1. $\sum_{ij} \xi_{ij} (C - \lambda_{ij} - r_{ij}) = 0$ из ограничений;
2. $\sum_i b_i \sum_j \lambda_{ij} y_{ij} = 0$ из ограничений;
3. $\langle \mathbf{A}^{-2} \mathbf{x}, \mathbf{x} \rangle = \langle \mathbf{A}^{-1} \mathbf{x}, \mathbf{A}^{-1} \mathbf{x} \rangle$, т.к. $\mathbf{x}^\top \mathbf{A}^{-2} \mathbf{x} = \mathbf{x}^\top \mathbf{A}^{-1} \mathbf{A}^{-1} \mathbf{x} = (\mathbf{A}^{-1} \mathbf{x})^\top \mathbf{A}^{-1} \mathbf{x}$
 \rightarrow введём обозначение: $\widehat{\mathbf{X}} = (\mathbf{A}^{-1})^\top \mathbf{X} = \mathbf{A}^{-1} \mathbf{X}$, т.к. \mathbf{A} симметрична.

$$\begin{aligned}\mathcal{L}(\lambda) &= -\frac{1}{2} \sum_{ij} \sum_{pq} \lambda_{ij} \lambda_{pq} y_{ij} y_{pq} \langle \widehat{\mathbf{x}}_{ij}, \widehat{\mathbf{x}}_{pq} \rangle - \sum_{ij} \lambda_{ij} y_{ij} \langle \mathbf{A}^{-1} \mathbf{B}, \mathbf{x}_{ij} \rangle + \sum_{ij} \lambda_{ij} = \\ &= -\frac{1}{2} \sum_{ij} \sum_{pq} \lambda_{ij} \lambda_{pq} y_{ij} y_{pq} \langle \widehat{\mathbf{x}}_{ij}, \widehat{\mathbf{x}}_{pq} \rangle + \sum_{ij} \lambda_{ij} (1 - y_{ij} \langle \mathbf{B}, \widehat{\mathbf{x}}_{ij} \rangle)\end{aligned}\tag{12}$$

Двойственная задача: $\arg \max_{\lambda} \mathcal{L}(\lambda)$

Значит, исходная задача по теореме Каруша-Куна-Таккера эквивалентна двойственной:

$$\begin{aligned}\text{minimize: } & \frac{1}{2} \sum_{(i,j), (p,q)} \lambda_{ij} \lambda_{pq} y_{ij} y_{pq} \langle \widehat{\mathbf{x}}_{ij}, \widehat{\mathbf{x}}_{pq} \rangle + \sum_{ij} \lambda_{ij} (y_{ij} \langle \mathbf{B}, \widehat{\mathbf{x}}_{ij} \rangle - 1) \\ \text{subject to: } & 0 \leq \lambda_{ij} \leq C, \\ & \forall i, \sum_j \lambda_{ij} y_{ij} = 0 \\ & i \in \{1, \dots, P\}, \\ & j \in \{0, \dots, D\}.\end{aligned}\tag{13}$$

4 Эксперимент

5 Заключение

ЛитератураReferences

- [1] Maria Kadukova, Sergei Grudinin. **Convex-PL: a novel knowledge-based potential for protein-ligand interactions deduced from structural databases using convex optimization.** Journal of Computer-Aided Molecular Design, October 2017, Volume 31, Issue 10, pp 943–958.
- [2] Maria Kadukova and Sergei Grudinin. **Docking of small molecules to farnesoid X receptors using AutoDock Vina with the Convex-PL potential : lessons learned from D3R Grand Challenge 2.** J. Comput.-Aided Mol. Des., 2017.
- [3] Sergei Grudinin, Maria Kadukova, Andreas Eisenbarth, Simon Marillet, Frédéric Cazals. **Predicting binding poses and affinities for protein-ligand complexes in the 2015 D3R Grand Challenge using a physical model with a statistical parameter estimation.** J Comput Aided Mol Des. 2016 Sep;30(9):791-804. Epub 2016 Oct 7.
- [4] S.P. Boyd and L. Vandenberghe. **Convex optimization.** Cambridge Univ Press, 2004.